

Sumário

1	Introdução	2
2	Material e Método	2
2.1	Base de dados	3
2.1.1	Pré-processamento	3
2.2	Algoritmo de treinamento	4
3	Análise experimental	5
3.1	Resultados	5
4	Conclusão	9

1 Introdução

O Índice de Desenvolvimento Humano Municipal (IDHM) é uma medida composta que sintetiza, para cada município brasileiro, indicadores de longevidade, educação e renda, permitindo comparar o nível de desenvolvimento humano entre diferentes regiões do país. Apesar de sua utilidade como resumo geral, o IDHM esconde uma grande heterogeneidade interna: municípios com valores de IDHM semelhantes podem apresentar perfis socioeconômicos bastante distintos entre si, seja em relação à estrutura de renda, ao acesso a infraestrutura, à dinâmica demográfica ou à composição do mercado de trabalho.

Nesse contexto, o presente trabalho tem como motivação ir além do valor agregado do IDHM e explorar, por meio de técnicas de aprendizado de máquina não supervisionado, os padrões de similaridade existentes entre os 5.565 municípios brasileiros a partir de um conjunto amplo de indicadores socioeconômicos do Censo de 2010. A escolha da tarefa de *agrupamento* (*clustering*) se justifica justamente por não exigir rótulos previamente definidos: o objetivo é permitir que os próprios dados revelem grupos de municípios com perfis de desenvolvimento parecidos, que podem não ser evidentes a partir da simples ordenação pelo IDHM.

A base de dados escolhida foi o Atlas do Desenvolvimento Humano no Brasil (Atlas 2013), produzido pelo PNUD, Ipea e Fundação João Pinheiro, que reúne mais de 200 indicadores por município para os anos de 1991, 2000 e 2010, além de informações de latitude, longitude e altitude. A riqueza e a dimensionalidade elevada dessa base tornam necessário um trabalho cuidadoso de seleção de variáveis e redução de dimensionalidade antes da aplicação dos algoritmos de agrupamento, etapa que é descrita em detalhe na Seção de Material e Método.

2 Material e Método

Para a realização deste trabalho foi utilizada a linguagem Python, em ambiente Jupyter Notebook, com apoio das bibliotecas *pandas* e *numpy* para manipulação dos dados, *scikit-learn* para padronização, redução de dimensionalidade e algoritmos de agrupamento, e *matplotlib/seaborn* para visualização dos resultados. O download da base de dados foi automatizado por meio da biblioteca *kagglehub*, que permite obter o conjunto de dados diretamente da plataforma Kaggle.

O problema escolhido foi o de agrupamento não supervisionado de municípios brasileiros com base em seus indicadores socioeconômicos do ano de 2010, com o objetivo de identificar perfis de desenvolvimento humano que não são diretamente capturados pelo valor agregado do IDHM. O algoritmo K-means, baseada em centróides, foi escolhido na abordagem. Como critérios de avaliação, foi utilizado o método do cotovelo (*elbow method*) sobre a inércia.

2.1 Base de dados

A base de dados utilizada é o Atlas do Desenvolvimento Humano no Brasil (Atlas 2013), que reúne dados brutos do Censo Demográfico, com informações de latitude, longitude e altitude por município. O arquivo original contém 16.695 linhas, correspondentes aos 5.565 municípios brasileiros observados em três anos (1991, 2000 e 2010), e 240 colunas de indicadores socioeconômicos. Para este trabalho, foi utilizado exclusivamente o corte referente ao ano de 2010, por ser o mais recente e completo disponível na base, evitando também problemas de comparabilidade decorrentes da criação e do desmembramento de municípios entre os censos anteriores. Após esse filtro, a base de trabalho ficou reduzida a 5.565 linhas, uma por município.

As colunas originais abrangem indicadores de renda e pobreza, educação (alfabetização, frequência escolar, distorção idade-série), longevidade e saúde, mercado de trabalho, infraestrutura domiciliar (água, esgoto, energia elétrica, coleta de lixo), estrutura etária da população e desigualdade de renda, além do próprio IDHM e de seus três subíndices (educação, longevidade e renda).

2.1.1 Pré-processamento

O conjunto original de 240 colunas apresenta forte redundância, tanto pela presença de variáveis auxiliares (denominadores usados apenas para o cálculo de taxas) quanto pela repetição de indicadores conceitualmente equivalentes em diferentes faixas etárias de referência. Por esse motivo, antes da padronização dos dados, foi realizada uma etapa de seleção de atributos que removeu:

- Colunas identificadoras e de contexto geográfico (ano, unidade federativa, códigos de município, nome do município, latitude, longitude e altitude), que não representam indicadores de desenvolvimento;
- Colunas de *peso*, isto é, denominadores populacionais usados apenas para o cálculo de taxas, e não indicadores em si;
- Contagens populacionais absolutas (população por sexo e faixa etária, PEA, PIA, totais), por refletirem o tamanho do município e não seu nível de desenvolvimento;
- Famílias de indicadores que se repetem apenas variando a faixa etária de referência (por exemplo, analfabetismo, conclusão do ensino fundamental e médio, atividade, desocupação, frequência escolar e distorção idade-série), das quais foi mantida apenas uma coluna canônica por família;
- Indicadores de fluxo escolar cruzado (nível de ensino versus idade fora do padrão), já cobertos pelos indicadores de frequência e distorção idade-série mantidos;

- A versão infantil dos indicadores de pobreza, mantendo-se apenas a versão geral;
- Variações da renda *per capita* e os quintis intermediários de renda, mantendo-se apenas os extremos (mais pobres e mais ricos), que carregam informação de desigualdade;
- Pares de variáveis quase idênticas ou complementares (como as relativas a acesso à luz elétrica, razões de dependência etária, taxas de sobrevivência e conclusão de ensino fundamental/médio), das quais foi mantida apenas uma de cada par;
- Indicadores de participação na renda por faixa, seguindo o mesmo critério de manter apenas os extremos mais informativos;
- O IDHM e seus três subíndices (educação, longevidade e renda), uma vez que são calculados diretamente a partir dos indicadores brutos já mantidos na base (como esperança de vida, renda *per capita* e indicadores educacionais), e sua manutenção representaria contagem duplicada da mesma informação.

Ao final dessa seleção, a base foi reduzida de 240 para 81 colunas de indicadores. Em seguida, as variáveis remanescentes foram padronizadas por meio do `StandardScaler` do `scikit-learn`, de forma a colocar todos os indicadores na mesma escala (média zero e desvio padrão unitário), etapa necessária dado que os algoritmos de agrupamento utilizados são sensíveis à escala das variáveis e as 81 colunas mantidas possuem unidades e amplitudes muito distintas entre si (percentuais, valores monetários, contagens de anos, entre outros).

Devido à elevada dimensionalidade remanescente e à forte correlação entre diversos indicadores socioeconômicos, foi aplicada, sobre os dados padronizados, uma Análise de Componentes Principais (PCA). A escolha do número de componentes foi feita a partir da variância acumulada explicada, adotando-se o critério de reter componentes suficientes para explicar 90% da variância total dos dados, o que resultou em 23 componentes principais, uma redução significativa em relação às 81 variáveis originais. Os componentes gerados foram posteriormente interpretados a partir de suas cargas (*loadings*), associando cada um deles às variáveis originais de maior peso positivo e negativo, o que permitiu identificar eixos de variação interpretáveis, como pobreza extrema, desigualdade urbana, informalidade no mercado de trabalho e infraestrutura habitacional, entre outros. É sobre esse espaço de 23 componentes principais que o algoritmo foi posteriormente aplicado.

2.2 Algoritmo de treinamento

Foi utilizada a implementação do `scikit-learn` com inicialização `k-means++`, `n_init=10` (dez reinicializações para reduzir a sensibilidade à inicialização aleatória

dos centróides) e `random_state=42` fixo para garantir reprodutibilidade. Para escolher o número de clusters k , o modelo foi treinado para $k \in \{2, \dots, 15\}$ e dois critérios foram avaliados: (i) o método do cotovelo sobre a inércia (soma das distâncias quadráticas intra-cluster), automatizado por meio do cálculo de derivadas discretas de primeira e segunda ordem, identificando o ponto de maior curvatura da curva; e (ii) o índice de silhueta, escolhendo o k que maximiza a separação/coesão média dos clusters.

Adicionalmente, os rótulos de cluster obtidos foram reassociados às coordenadas geográficas (latitude e longitude) originais de cada município – mantidas à parte durante o treinamento, em `colunas_id` – permitindo visualizar a distribuição espacial dos agrupamentos sobre o mapa do Brasil como forma adicional de avaliar a coerência dos clusters encontrados.

3 Análise experimental

3.1 Resultados

A aplicação dos dois critérios de escolha de k resultou em valores distintos: o método do cotovelo indicou $k = 3$, enquanto o índice de silhueta indicou $k = 2$. Essa divergência não foi tratada como um problema a ser resolvido por um único valor "correto", mas como uma oportunidade de análise: optou-se por treinar e interpretar três cenários ($k = 2$, $k = 3$ e $k = 4$), a fim de entender que estrutura socioeconômica cada granularidade de agrupamento revela.

Para $k = 2$, o algoritmo separou os municípios essencialmente em dois grandes perfis: um cluster de municípios com bons indicadores socioeconômicos (menor pobreza, melhor infraestrutura de água/esgoto e paredes adequadas, maior renda per capita nos quintis mais pobres) e outro de municípios com indicadores ruins nas mesmas dimensões. A hipótese levantada é a de que esse corte binário reflete, em grande medida, a desigualdade estrutural entre as regiões Sul/Sudeste e Norte/Nordeste do país – hipótese que a visualização geográfica corrobora visualmente, já que os dois clusters aparecem espacialmente bem segregados no mapa.




Figura 1: Mapa do Brasil para $k = 2$

Para $k = 3$, o agrupamento se tornou mais refinado, revelando um terceiro perfil intermediário: (i) um cluster de municípios pobres, mas com desigualdade social mediana – o que apresentou, de modo geral, a menor divergência em relação à média nacional entre os três grupos; (ii) um cluster de municípios claramente desenvolvidos, com renda per capita dos 20% mais pobres cerca do dobro da média nacional e maior proporção de população idosa; e (iii) um cluster de municípios com baixo desenvolvimento, marcado por indicadores muito ruins de saneamento (água e esgoto), qualidade habitacional (paredes inadequadas) e extrema pobreza.

Modelo com $k = 3$




Figura 2: Mapa do Brasil para $k = 3$

Para $k = 4$, a divisão manteve o cluster de municípios desenvolvidos praticamente inalterado (correspondendo ao cluster mais próspero identificado em $k = 3$), mas separou o antigo grupo de baixo desenvolvimento em dois subperfis distintos: um cluster amplo de municípios pobres e aparentemente estagnados no interior do país (com indicadores elevados de dependência de idosos e de ocupados sem rendimento); e um cluster menor e mais extremo, de municípios com péssima infraestrutura básica e baixíssima formalização no mercado de trabalho, interpretado como agrupando localidades geograficamente isoladas e com privação múltipla e mais severa que o restante do grupo de baixo desenvolvimento.




Figura 3: Mapa do Brasil para $k = 4$

A visualização geográfica dos clusters (latitude/longitude de cada município, coloridos por cluster) para $k \in \{2, 3, 4\}$ reforça a interpretação socioeconômica dos grupos: já em $k = 2$, é possível observar uma segregação espacial nítida entre os municípios de melhor desempenho, concentrados no Sul, Sudeste e em polos urbanos isolados de outras regiões, e os municípios de pior desempenho, concentrados no Norte e Nordeste. Em $k = 3$ e $k = 4$, essa mesma estrutura espacial se mantém, com os clusters adicionais aparecendo como refinamentos dentro dessas macrorregiões, e não como uma reorganização espacial completamente distinta – evidência de que os agrupamentos obtidos por variáveis puramente socioeconômicas têm forte coerência geográfica, mesmo sem que latitude/longitude tenham sido usadas como variáveis de treino.

4 Conclusão

O agrupamento dos municípios brasileiros a partir de indicadores socioeconômicos do Censo 2010, reduzidos via PCA a 23 componentes principais, mostrou-se uma abordagem eficaz para revelar padrões de desenvolvimento que vão além do que o valor agregado do IDHM comunica isoladamente. Com o K-means, foi possível identificar, de forma consistente para $k = 2$, $k = 3$ e $k = 4$, uma clivagem estrutural entre municípios desenvolvidos e municípios vulneráveis, refinada progressivamente em subperfis – como municípios pobres, porém com desigualdade moderada, e municípios extremamente vulneráveis e geograficamente isolados, com privação simultânea em renda, saneamento e formalização do trabalho. A validação por meio de mapas de latitude/longitude reforçou a coerência desses agrupamentos, evidenciando forte correspondência entre os clusters puramente socioeconômicos e a conhecida desigualdade regional brasileira entre Sul/Sudeste e Norte/Nordeste, mesmo sem o uso de variáveis geográficas no treinamento.

Uma limitação é a escolha, ainda que justificada, de um critério de corte de 90% de variância explicada no PCA, que descarta parte da informação original e pode ocultar padrões presentes apenas nos componentes de menor variância (como os enclaves econômicos muito específicos identificados nos PCs finais).

Colab: <https://colab.research.google.com/drive/1roYUga7F5ocj0HqsmTiHQUSQNRHaNGyF?usp=sharing>

Referências

- [1] BRASIL COM CENSO. **Atlas IDHM Brasil: 1991, 2000 e 2010 (Lat e Long)**. Versão 1. San Francisco: Kaggle, 2023. Base de dados brutos adaptada do Atlas do Desenvolvimento Humano no Brasil, contendo coordenadas geográficas e altitude. Disponível em: <<https://www.kaggle.com/datasets/BrasilComCenso/atlas-idhm-brasil-1991-2000-e-2010-lat-e-long>>.
- [2] VALEJO, A. D. B. **Aula 11 - Aprendizado não supervisionado**. Material didático da disciplina 1001524 - Aprendizado de Máquina 1. São Carlos: Departamento de Computação (DC), Universidade Federal de São Carlos (UFSCar), 2026. Slides de aula.
- [3] VALEJO, A. D. B. **Aula 11 - K-médias**. Material didático da disciplina 1001524 - Aprendizado de Máquina 1. São Carlos: Departamento de Computação (DC), Universidade Federal de São Carlos (UFSCar), 2026. Slides de aula.